Tugas Mata Kuliah
Pembelajaran Mesin

KLASIFIKASI KELULUSAN UJIAN SISWA MENGGUNAKAN GAUSSIAN NAÏVE BAYES



Oleh:

Giovanni Khaidzan
10124193

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS KOMPUTER INDONESIA
2026

BAB I - DESKRIPSI DATASET

1.1 Sumber Data

Data yang digunakan dalam laporan ini diperoleh dari platform Kaggle dengan rincian sebagai berikut:

- **Nama Dataset:** *Student Exam Performance & Success Dataset*
- **Pemilik / Pengunggah:** mobeenfatimah
- **Sumber:** Kaggle
- **Dataset:** https://www.kaggle.com/datasets/mobeenfatimah/student-exam-performance-and-success-dataset
- **Nama File:** *student_exam_performance.csv*
- **Format File:** CSV (Comma-Separated Values)
- **Ukuran Data:** 100.000 baris dan 44 kolom
- **Tanggal Akses:** 11 Oktober 2026

1.2 Deskripsi Umum Dataset

Dataset ini diambil dari Kaggle dan berisi catatan 100.000 peserta didik dengan 44 kolom. Setiap baris mewakili satu peserta didik, dan kolom-kolomnya mencatat latar belakang, kebiasaan belajar, kondisi psikologis, sampai hasil ujiannya. Menurut deskripsi di Kaggle, dataset ini ditujukan untuk memprediksi nilai ujian dan status lulus atau tidaknya peserta didik.

Peserta didik yang tercatat berusia 14 sampai 20 tahun dengan rata-rata sekitar 17 tahun, sesuai keterangan kolom *age* di Kaggle. Sebanyak 59.752 peserta didik (59,75%) berada di jenjang *High School* dan 40.248 (40,25%) di jenjang *Undergraduate*. Rentang dan rata-rata usia di kedua jenjang hampir sama. Dari sisi jenis kelamin, terdapat 49.130 laki-laki (49,13%), 48.841 perempuan (48,84%), dan 2.029 berkategori *Other* (2,03%).

Ke-44 kolom tersebut dapat dikelompokkan menjadi delapan bagian utama:

- **Identitas dan demografi:** *student_id*, *age*, *gender*, *education_level*, *school_type*, dan *urban_rural*.
- **Latar belakang keluarga:** *family_income* dan *parent_education*.
- **Riwayat akademik:** *previous_exam_score*, *previous_gpa*, *attendance_percentage*, *assignment_completion_rate*, dan *class_participation*.
- **Kebiasaan belajar:** *study_hours_per_day*, *self_study_hours*, *private_tuition*, *online_learning_hours*, *study_consistency*, *study_environment*, *study_method*, *revision_frequency*, *practice_tests_completed*, *notes_quality*, dan *time_management_score*.
- **Pola tidur dan gaya hidup:** *sleep_hours*, *sleep_quality*, *daily_screen_time*, *physical_activity_hours*, dan *break_frequency*.
- **Kondisi psikologis:** *stress_level*, *motivation_level*, dan *exam_anxiety_level*.
- **Akses teknologi:** *internet_access*, *device_availability*, *educational_app_usage*, dan *online_course_hours*.

- **Persiapan dan hasil ujian:** *exam_difficulty*, *exam_preparation_days*, *questions_attempted*, *questions_correct*, *exam_score*, *performance_grade*, *pass_status*, dan *performance_level*.

Dari sisi tipe data, terdapat 22 kolom bertipe teks, 14 kolom desimal, dan 8 kolom bilangan bulat, sehingga fitur yang ada merupakan campuran numerik, ordinal, dan nominal. Nilai ujian (*exam_score*) berkisar antara 0 sampai 100 dengan rata-rata sekitar 61,95.

Kolom *pass_status* dipilih sebagai target klasifikasi dengan dua kelas, yaitu *Pass* dan *Fail*. Proporsi kelasnya tidak seimbang, yaitu 77,39% berstatus *Pass* dan 22,61% berstatus *Fail* (sekitar 77% : 23%). Berdasarkan kolom *performance_grade*, sebaran nilai hurufnya adalah A sebanyak 7.519 (7,52%), B sebanyak 13.190 (13,19%), C sebanyak 21.794 (21,79%), D sebanyak 34.886 (34,89%), dan F sebanyak 22.611 (22,61%). Grade F inilah yang setara dengan status *Fail*, sedangkan grade A sampai D setara dengan status *Pass*.

Tiga kolom lain pada kelompok terakhir (*exam_score*, *performance_grade*, dan *performance_level*) dihitung dari nilai ujian yang sama dengan target, sehingga nantinya tidak digunakan sebagai fitur guna menghindari *data leakage*.

Data ini juga belum sepenuhnya bersih karena terdapat tujuh kolom yang memiliki nilai kosong, yaitu *parent_education* (6,53%), *previous_gpa* (7,79%), *attendance_percentage* (9,86%), *notes_quality* (8,41%), *sleep_quality* (6,99%), *device_availability* (2,96%), dan *time_management_score* (9,61%). Pemeriksaan duplikat tidak menemukan baris yang sama.

1.3 Daftar Fitur Dataset

No	Nama Fitur	Penjelasan	Contoh Nilai
1	student_id	Kode unik pengenal setiap peserta didik (STU_000001 sampai STU_100000)	STU_000001
2	age	Usia peserta didik dalam tahun (14 sampai 20)	20
3	gender	Identitas gender yang dilaporkan sendiri (Male, Female, Other)	Female
4	education_level	Jenjang pendidikan saat ini (High School atau Undergraduate)	High School
5	school_type	Jenis lembaga pendidikan (Public, Private, Charter)	Public
6	family_income	Tingkat pendapatan keluarga, dari Low sampai High (Low, Lower-Middle, Middle, Upper-Middle, High)	Middle
7	parent_education	Gelar tertinggi yang diselesaikan orang tua (High School, Associate, Bachelor, Master, Doctorate)	Master

No	Nama Fitur	Penjelasan	Contoh Nilai
8	urban_rural	Lingkungan tempat tinggal (Urban, Suburban, Rural)	Rural
9	previous_exam_score	Persentase nilai ujian sebelumnya (30 sampai 100)	78.36
10	previous_gpa	IPK/GPA kumulatif sebelumnya dengan skala 4,0 (1,00 sampai 4,00)	2.95
11	attendance_percentage	Persentase kehadiran (sekitar 46 sampai 100)	81.49
12	assignment_completion_rate	Persentase tugas yang diselesaikan (20 sampai 100)	65.18
13	class_participation	Keaktifan di kelas (Low, Medium, High)	Medium
14	study_hours_per_day	Jam belajar per hari (0,5 sampai 12)	4.94
15	self_study_hours	Jam belajar mandiri (0,25 sampai 10)	2.63
16	private_tuition	Mengikuti les privat (0 = tidak, 1 = ya)	0
17	online_learning_hours	Jam belajar daring (0 sampai 15)	1.75
18	study_consistency	Konsistensi belajar (Low, Medium, High)	Medium
19	study_environment	Kondisi lingkungan belajar (Quiet, Moderate, Noisy)	Moderate
20	study_method	Metode belajar (Flashcards, Summarizing, Group Study, Practice Tests, Self-Reading)	Flashcards
21	revision_frequency	Seberapa sering mengulang materi (Rarely, Weekly, Daily)	Rarely
22	practice_tests_completed	Jumlah latihan soal yang diselesaikan (0 sampai 20)	8
23	notes_quality	Kualitas catatan belajar (Poor, Average, Excellent)	Average
24	sleep_hours	Jam tidur per hari (3 sampai 11)	6.31
25	sleep_quality	Kualitas tidur (Poor, Fair, Good, Excellent)	Excellent
26	daily_screen_time	Lama waktu layar per hari dalam jam (1 sampai 12,08)	3.8
27	physical_activity_hours	Jam aktivitas fisik (0 sampai 12)	0.93
28	break_frequency	Seberapa sering istirahat saat belajar (Rarely, Occasionally, Frequently)	Frequently
29	stress_level	Tingkat stres, bilangan bulat 5 sampai 10	10

No	Nama Fitur	Penjelasan	Contoh Nilai
30	motivation_level	Tingkat motivasi (Low, Medium, High)	High
31	internet_access	Punya akses internet (0 = tidak, 1 = ya)	1
32	device_availability	Ketersediaan perangkat belajar (Shared atau Dedicated)	Shared
33	educational_app_usage	Intensitas pemakaian aplikasi belajar (Low, Moderate, High)	Low
34	online_course_hours	Jam mengikuti kursus daring (0 sampai 20)	2.15
35	exam_difficulty	Tingkat kesulitan ujian (Easy, Medium, Hard)	Medium
36	exam_preparation_days	Jumlah hari persiapan ujian (1 sampai 30)	27
37	questions_attempted	Jumlah soal yang dikerjakan (85 sampai 100)	95
38	questions_correct	Jumlah soal yang dijawab benar (0 sampai 100)	86
39	time_management_score	Skor kemampuan mengatur waktu (sekitar 17 sampai 100)	87.17
40	exam_anxiety_level	Tingkat kecemasan menghadapi ujian (1 sampai 10)	9.39
41	exam_score	Nilai ujian akhir (0 sampai 100)	90.4
42	performance_grade	Nilai huruf hasil ujian (A, B, C, D, F)	A
43	pass_status	Status kelulusan (Pass atau Fail), target klasifikasi	Pass
44	performance_level	Tingkat capaian (Low, Medium, High)	High

Secara keseluruhan, ke-44 fitur di atas mencakup berbagai aspek komprehensif yang saling berkaitan dalam memprediksi kelulusan siswa, mulai dari identitas demografi, latar belakang keluarga, riwayat akademik, kebiasaan dan lingkungan belajar, pola tidur, hingga kondisi psikologis dan persiapan ujian.

1.4 Variabel Target

Variabel target yang diprediksi dalam tugas ini adalah *pass_status*, yaitu status kelulusan peserta didik. Kolom ini bersifat kategorik dengan dua kelas, yaitu *Pass* (lulus) dan *Fail* (tidak lulus), sehingga termasuk klasifikasi biner. Berdasarkan pengamatan pada data, seluruh peserta didik berstatus *Pass* memiliki nilai ujian (*exam_score*) 50 atau lebih, sedangkan yang berstatus *Fail* memiliki nilai di bawah 50. Kolom *pass_status* sudah berisi label pada seluruh data, sehingga digunakan sebagai kunci jawaban untuk melatih model dan sebagai pembanding untuk menilai hasil prediksi pada data uji. Untuk itu, kolom ini dipisahkan dari fitur dan disimpan sebagai target (y), sedangkan kolom lainnya, kecuali kolom

turunan nilai ujian dan kolom pengenal, digunakan sebagai fitur (*X*) untuk memprediksi kolom ini.

1.5 Kondisi Awal Data

- **Pemuatan Dataset & Cek Kesehatan Awal:** Dataset terdiri dari 100.000 baris dan 44 kolom. Tipe data terbagi menjadi 22 kolom kategorik/teks, 14 kolom desimal (float64), dan 8 kolom bilangan bulat (int64).
- **Audit Data Duplikat:** Pemeriksaan berdasarkan *student_id* maupun seluruh kombinasi fitur menunjukkan tidak terdapat baris data duplikat (0 duplikat).
- **Audit Missing Values:** Terdapat 7 kolom yang memiliki nilai kosong, yaitu *attendance_percentage* (9,86%), *time_management_score* (9,61%), *notes_quality* (8,41%), *previous_gpa* (7,79%), *sleep_quality* (6,99%), *parent_education* (6,53%), dan *device_availability* (2,96%). Secara total, sekitar 42% baris memiliki setidaknya satu nilai kosong.
- **Deteksi Outlier (IQR):** Metode Interquartile Range (IQR) mendeteksi outlier pada beberapa fitur numerik, seperti *study_hours_per_day* dan *online_learning_hours*. Namun, nilai-nilai ini masih berada dalam batas logis aktivitas belajar sehingga tidak dibuang.
- **Audit Inkonsistensi Skala Fitur Numerik:** Fitur numerik memiliki rentang yang bervariasi, misalnya skala 0–4 (*previous_gpa*), 0–100 (*attendance_percentage*), dan jam harian. Perbedaan skala ini perlu diperhatikan saat memilih teknik encoding dan algoritma pemodelan.
- **Audit Keseimbangan Kelas Target (Class Imbalance):** Distribusi target *pass_status* menunjukkan proporsi kelas *Pass* sebesar 77,39% (77.390 sampel) dan *Fail* sebesar 22,61% (22.610 sampel). Ketidakseimbangan ini memerlukan stratifikasi saat pembagian data latih/uji.
- **Audit Kardinalitas & Risiko Data Leakage:** Fitur kategorik secara umum memiliki kardinalitas rendah hingga sedang. Namun, kolom *student_id* bersifat unik per baris sehingga harus dihapus. Kolom *exam_score*, *performance_grade*, dan *performance_level* diidentifikasi sebagai sumber *data leakage* karena merupakan turunan langsung dari hasil ujian akhir.

Rapor Diagnosis Kondisi Awal Dataset: Dataset secara umum memiliki kualitas struktur yang baik tanpa duplikat, namun membutuhkan penanganan khusus pada imputasi missing values (7 kolom), pembuangan kolom berisiko *leakage*, encoding variabel kategorik, serta penanganan ketidakseimbangan kelas target.

BAB II - JENIS DATA BERDASARKAN SKALA PENGUKURAN

2.1 Klasifikasi Skala Pengukuran Fitur

Berikut adalah klasifikasi seluruh 44 fitur yang terdapat dalam dataset berdasarkan skala pengukurannya (Nominal, Ordinal, Interval, dan Rasio):

Fitur	Skala	Alasan
student_id	Nominal	Kode unik pengenal peserta didik tanpa ada tingkatan nilai.
age	Rasio	Usia numerik dalam tahun yang memiliki nilai nol mutlak.
gender	Nominal	Kategori jenis kelamin (Male, Female, Other) tanpa urutan.
education_level	Ordinal	Tingkat pendidikan yang memiliki urutan hierarki (High School < Undergraduate).
school_type	Nominal	Jenis institusi (Public, Private, Charter) tanpa adanya tingkatan.
family_income	Ordinal	Kategori tingkatan ekonomi keluarga (Low hingga High).
parent_education	Ordinal	Gelar tertinggi orang tua yang terurut (High School hingga Doctorate).
urban_rural	Nominal	Kategori area tempat tinggal (Urban, Suburban, Rural) tanpa peringkat.
previous_exam_score	Rasio	Persentase nilai numerik yang memiliki nol mutlak (0–100%).
previous_gpa	Rasio	Indeks prestasi kumulatif numerik dalam skala 0,00–4,00.
attendance_percentage	Rasio	Persentase tingkat kehadiran numerik dengan nol mutlak.
assignment_completion_rate	Rasio	Persentase pengerjaan tugas dalam skala kontinu 0–100%.
class_participation	Ordinal	Tingkat keaktifan siswa yang terurut (Low, Medium, High).
study_hours_per_day	Rasio	Durasi waktu belajar harian dalam satuan jam.
self_study_hours	Rasio	Durasi waktu belajar mandiri dalam jam.
private_tuition	Nominal (Biner)	Penanda dikotomis keikutsertaan les (0 = Tidak, 1 = Ya).
online_learning_hours	Rasio	Lama waktu pembelajaran online dalam jam.

Fitur	Skala	Alasan
study_consistency	Ordinal	Tingkat konsistensi pola belajar (Low, Medium, High).
study_environment	Nominal	Kondisi lingkungan suasana belajar (Quiet, Moderate, Noisy).
study_method	Nominal	Metode belajar yang diterapkan (Flashcards, Summarizing, dll.).
revision_frequency	Ordinal	Frekuensi pengulangan materi (Rarely, Weekly, Daily).
practice_tests_completed	Rasio	Jumlah latihan ujian yang diselesaikan secara diskrit (0–20).
notes_quality	Ordinal	Tingkat kualitas catatan belajar (Poor, Average, Excellent).
sleep_hours	Rasio	Durasi jam tidur per hari dalam angka kontinu.
sleep_quality	Ordinal	Tingkat kualitas tidur (Poor, Fair, Good, Excellent).
daily_screen_time	Rasio	Durasi waktu menatap layar harian dalam jam.
physical_activity_hours	Rasio	Durasi jam aktivitas fisik harian.
break_frequency	Ordinal	Tingkat frekuensi istirahat (Rarely, Occasionally, Frequently).
stress_level	Interval	Skala tingkat stres (5–10) tanpa nilai nol mutlak.
motivation_level	Ordinal	Tingkat motivasi belajar terurut (Low, Medium, High).
internet_access	Nominal (Biner)	Ketersediaan akses internet (0 = Tidak, 1 = Ya).
device_availability	Nominal	Kategori ketersediaan perangkat (Shared, Dedicated).
educational_app_usage	Ordinal	Intensitas penggunaan aplikasi (Low, Moderate, High).
online_course_hours	Rasio	Durasi jam mengikuti kursus daring.
exam_difficulty	Ordinal	Tingkat kesulitan soal ujian (Easy, Medium, Hard).
exam_preparation_days	Rasio	Jumlah hari persiapan sebelum ujian (1–30 hari).
questions_attempted	Rasio	Jumlah butir soal yang dikerjakan secara diskrit.
questions_correct	Rasio	Jumlah butir soal yang dijawab dengan benar.

Fitur	Skala	Alasan
time_management_score	Rasio	Skor numerik kemampuan manajemen waktu (0–100).
exam_anxiety_level	Interval	Skala kecemasan numerik (1–10) tanpa nol mutlak.
exam_score	Rasio	Nilai akhir numerik (0–100) dengan nilai nol mutlak.
performance_grade	Ordinal	Nilai mutu bertingkat (F, D, C, B, A).
pass_status	Nominal (Biner)	Status kelulusan kategorik (Fail, Pass) sebagai target.
performance_level	Ordinal	Tingkat capaian kinerja bertingkat (Low, Medium, High).

BAB III - PEMROSESAN DATA

3.1 Pembuangan Fitur (Pencegahan Data Leakage)

- **Pemisahan Variabel Target (y):** Kolom *pass_status* dipisahkan secara eksplisit dari matriks prediktor (X) sebagai variabel terikat yang akan diprediksi. Pemisahan ini merupakan syarat mutlak dalam kerangka *supervised learning* guna mencegah pembocoran label saat proses pelatihan model.
- **Eliminasi Identifikator Unik:** Kolom *student_id* dihapus karena hanya berfungsi sebagai identitas unik siswa tanpa mengandung bobot statistik atau korelasi teoretis terhadap performa akademik. Mempertahankan kolom ini berpotensi memicu masalah *overfitting* di mana model menghafal nomor identitas siswa.
- **Pencegahan Kebocoran Data (Data Leakage):** Tiga kolom yang berhubungan langsung dengan hasil ujian, yaitu *exam_score*, *performance_grade*, dan *performance_level*, dihapus dari himpunan prediktor. Analisis empiris menunjukkan bahwa variabel *pass_status* ditentukan secara deterministik oleh nilai ujian (*exam_score* $\geq$ 50 dikategorikan *Pass*, sedangkan $<$ 50 dikategorikan *Fail*). Keikutsertaan atribut-atribut tersebut akan menyebabkan kebocoran informasi target (*data leakage*), sehingga menghasilkan performa model yang terdistorsi secara artifisial.

3.2 Penanganan Missing Values

Pemeriksaan kualitas data mengidentifikasi adanya nilai kosong (*missing values*) pada 7 fitur dari total 44 kolom. Nilai imputasi (median untuk numerik dan modus untuk kategorikal) dihitung dari keseluruhan data sebelum proses split, agar selaras dengan catatan evaluasi pada sub-bab 4.4.5.

- **Imputasi Fitur Numerik:** Nilai kosong pada kolom numerik (seperti *attendance_percentage*, *time_management_score*, dan *previous_gpa*) diimputasi menggunakan nilai median.
- **Imputasi Fitur Kategorikal:** Nilai kosong pada kolom kategorikal (seperti *notes_quality*, *sleep_quality*, *parent_education*, dan *device_availability*) diimputasi menggunakan modus (kategori dengan frekuensi kemunculan tertinggi).
-

3.3 Encoding Fitur Kategorikal

- **Ordinal Encoding:** Diterapkan pada fitur-fitur kategorikal yang memiliki urutan logis atau hierarki, seperti *education_level*, *family_income*, *parent_education*, *class_participation*, *study_consistency*, *revision_frequency*, *notes_quality*, *sleep_quality*, *break_frequency*, *motivation_level*, *educational_app_usage*, dan *exam_difficulty*. Pemetaan nilai dikonversi menjadi tingkatan angka (misal: 0, 1, 2, dst.) untuk mempertahankan informasi urutannya.
- **One-Hot Encoding:** Diterapkan pada fitur nominal tanpa tingkatan, seperti *gender*, *school_type*, *urban_rural*, *study_environment*,

study_method, dan *device_availability*. Proses ini menggunakan parameter *drop_first=True* untuk membuang satu kategori basis guna menghindari redundansi data dan jebakan variabel boneka (*dummy variable trap*). Setelah seluruh proses encoding, dihasilkan total 46 kolom fitur akhir (termasuk variabel prediktor).

- **Encoding Fitur Biner & Target:** Fitur biner seperti *private_tuition* dan *internet_access* sudah berada dalam format numerik biner (0 dan 1). Sementara variabel target *pass_status* di-encode menggunakan Label Encoding menjadi 1 untuk *Pass* dan 0 untuk *Fail*.

3.4 Audit Duplikat dan Outlier

- **Pengecekan Duplikat:** Sebagaimana telah dijelaskan pada sub-bab 1.5, tidak ditemukan adanya baris data duplikat dalam dataset sehingga seluruh 100.000 sampel tetap dipertahankan.
- **Penanganan Outlier:** Berdasarkan deteksi metode Interquartile Range (IQR), ditemukan pencilan pada beberapa fitur numerik harian. Namun, nilai outlier tersebut tetap dipertahankan karena masih berada dalam batas logis variasi perilaku belajar nyata serta jumlahnya tidak menggeser nilai rata-rata (mean) dan varians populasi secara signifikan, sehingga aman untuk dimodelkan oleh algoritma Gaussian Naïve Bayes.

3.5 Scaling Fitur (Analisis Algoritma Naïve Bayes)

Proses pemosisian ulang skala nilai (*feature scaling*) seperti Normalisasi (MinMax) atau Standardisasi (StandardScaler) tidak diwajibkan secara ketat pada algoritma Gaussian Naïve Bayes. Algoritma ini menghitung probabilitas berdasarkan estimasi rata-rata (*mean*) dan varians masing-masing fitur secara terpisah untuk tiap kelas target, sehingga tidak sensitif terhadap perbedaan rentang nilai antar fitur numerik.

3.6 Pembagian Data Latih dan Data Uji

Untuk menguji performa generalisasi model secara objektif, dataset dibagi menjadi data latih (*training set*) dan data uji (*testing set*) dengan ketentuan sebagai berikut:

- **Rasio Split & Reproduosibilitas:** Data dibagi dengan proporsi 80% untuk data latih (80.000 sampel) dan 20% untuk data uji (20.000 sampel). Penggunaan parameter *random_state=42* diterapkan untuk menjamin keterulangan (reproducibility) hasil pembagian data secara konsisten.
- **Stratified Sampling:** Penggunaan parameter *stratify = y* diterapkan saat pembagian data untuk memastikan proporsi kelas target (77,39% *Pass* dan 22,61% *Fail*) terjaga secara konsisten baik pada data latih maupun data uji.

BAB IV - IMPLEMENTASI DAN HASIL

4.1 Kode Program

1. Pembuangan Fitur (Pencegahan Data Leakage & Identifier)

```python
# Memisahkan target dan membuang fitur identifier
serta fitur penyebab data leakage
y = df['pass_status']
X = df.drop(columns=[
    'student_id',          # Identifier unik
    'exam_score',          # Determinasi langsung ke
pass_status
    'performance_grade',   # Turunan langsung
exam_score
    'performance_level',   # Turunan langsung
exam_score
    'pass_status'          # Target variable
])
```

2. Penanganan Missing Value

```python
# Imputasi Median untuk Fitur Numerik
num_cols_missing = ['attendance_percentage',
'time_management_score', 'previous_gpa']
for col in num_cols_missing:
    X[col] = X[col].fillna(X[col].median())

# Imputasi Modus untuk Fitur Kategorikal
cat_cols_missing = ['notes_quality',
'sleep_quality', 'parent_education',
'device_availability']
for col in cat_cols_missing:
    X[col] = X[col].fillna(X[col].mode()[0])
```

3. Ordinal Encoding (Fitur Kategorikal Bertingkat)

```python
from sklearn.preprocessing import OrdinalEncoder

ordinal_mappings = {
```

```
    'education_level': ['High School',
'Undergraduate'],
    'family_income': ['Low', 'Lower-Middle',
'Middle', 'Upper-Middle', 'High'],
    'parent_education': ['High School', 'Associate',
'Bachelor', 'Master', 'Doctorate'],
    'class_participation': ['Low', 'Medium',
'High'],
    'study_consistency': ['Low', 'Medium', 'High'],
    'revision_frequency': ['Rarely', 'Weekly',
'Daily'],
    'notes_quality': ['Poor', 'Average',
'Excellent'],
    'sleep_quality': ['Poor', 'Fair', 'Good',
'Excellent'],
    'break_frequency': ['Rarely', 'Occasionally',
'Frequently'],
    'motivation_level': ['Low', 'Medium', 'High'],
    'educational_app_usage': ['Low', 'Moderate',
'High'],
    'exam_difficulty': ['Easy', 'Medium', 'Hard']
}

for col, categories in ordinal_mappings.items():
    encoder =
OrdinalEncoder(categories=[categories])
    X[col] = encoder.fit_transform(X[[col]])
```

4. One-Hot Encoding (Fitur Nominal Non-Bertingkat)

Python

```
nominal_cols = ['gender', 'school_type',
'urban_rural', 'study_environment', 'study_method',
'device_availability']
X = pd.get_dummies(X, columns=nominal_cols,
drop_first=True)
```

5. Encoding Target & Pembagian Data Latih/Uji

Python

```
from sklearn.model_selection import train_test_split
```

```
from sklearn.preprocessing import LabelEncoder

# Label Encoding Target (Pass=1, Fail=0)
le = LabelEncoder()
y = le.fit_transform(y)

# Pembagian Data Latih 80% dan Data Uji 20% dengan
Stratified Sampling
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

6. Pelatihan & Evaluasi Gaussian Naïve Bayes

Python

```
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import classification_report,
confusion_matrix, accuracy_score

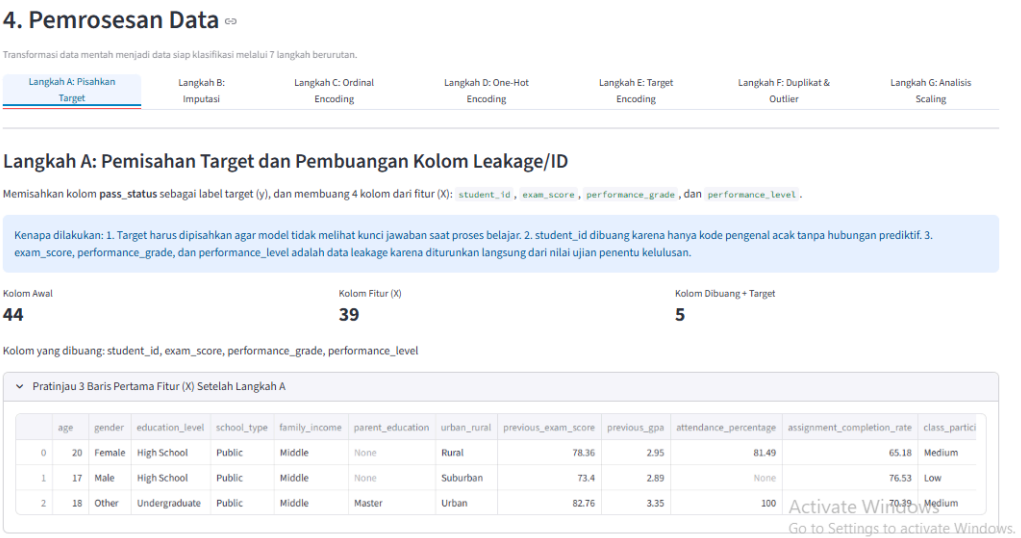
# Inisialisasi dan Pelatihan Model
model = GaussianNB()
model.fit(X_train, y_train)

# Prediksi pada Data Uji
y_pred = model.predict(X_test)

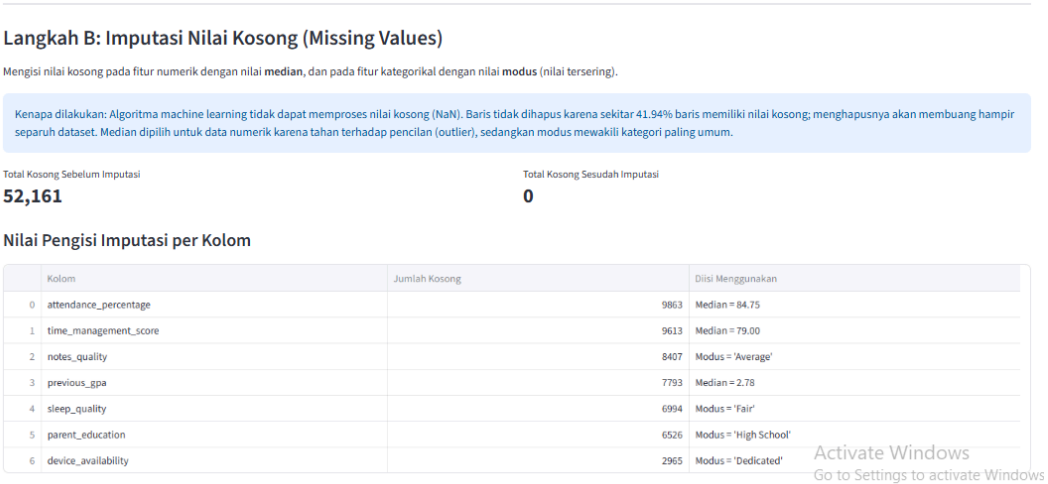
# Evaluasi Model
print("Accuracy:", accuracy_score(y_test, y_pred))
print("\nClassification Report:\n",
classification_report(y_test, y_pred,
target_names=le.classes_))
print("\nConfusion Matrix:\n",
confusion_matrix(y_test, y_pred))
```

4.2 Hasil Pemrosesan Data

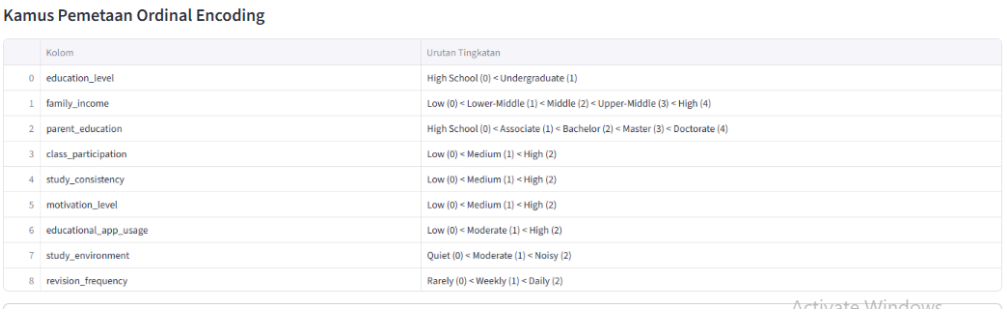
Setelah seluruh rangkaian preprocessing dilakukan, dihasilkan total 46 kolom fitur akhir. Berikut ini adalah tampilan sampel lima data teratas dan lima data terbawah dari dataset sebelum dilakukan tahapan pemrosesan awal:



Gambar 4.1 Tangkapan layar Langkah A: Pemisahan target pass_status serta pembuangan kolom student_id dan kolom turunan nilai ujian untuk mencegah data leakage.



Gambar 4.2 Tangkapan layar Langkah B: Hasil imputasi missing values menggunakan median untuk fitur numerik dan modus untuk fitur kategorikal.

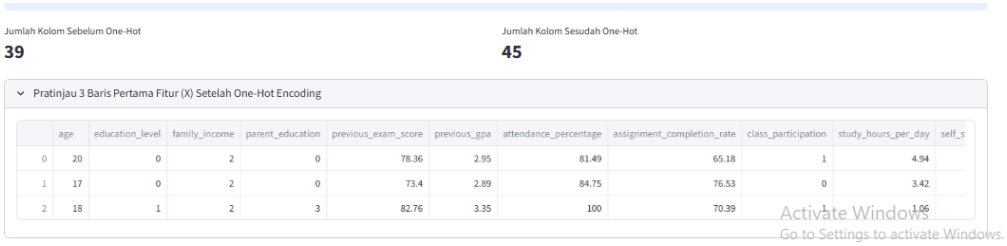


Kamus Pemetaan Ordinal Encoding

	Kolom	Urutan Tingkatan
0	education_level	High School (0) < Undergraduate (1)
1	family_income	Low (0) < Lower-Middle (1) < Middle (2) < Upper-Middle (3) < High (4)
2	parent_education	High School (0) < Associate (1) < Bachelor (2) < Master (3) < Doctorate (4)
3	class_participation	Low (0) < Medium (1) < High (2)
4	study_consistency	Low (0) < Medium (1) < High (2)
5	motivation_level	Low (0) < Medium (1) < High (2)
6	educational_app_usage	Low (0) < Moderate (1) < High (2)
7	study_environment	Quiet (0) < Moderate (1) < Noisy (2)
8	revision_frequency	Rarely (0) < Weekly (1) < Daily (2)

Activate Windows

Gambar 4.3 Tangkapan layar Langkah C: Kamus pemetaan Ordinal Encoding untuk fitur-fitur kategorikal bertingkat.



Jumlah Kolom Sebelum One-Hot
39

Jumlah Kolom Sesudah One-Hot
45

Pratinjau 3 Baris Pertama Fitur (X) Setelah One-Hot Encoding

	age	education_level	family_income	parent_education	previous_exam_score	previous_gpa	attendance_percentage	assignment_completion_rate	class_participation	study_hours_per_day	self_s
0	20	0	2	0	78.36	2.95	81.49	65.18	1	4.94	
1	17	0	2	0	73.4	2.89	84.75	76.53	0	3.42	
2	18	1	2	3	82.76	3.35	100	70.39	1	1.06	

Activate Windows
Go to Settings to activate Windows.

Gambar 4.4 Tangkapan layar Langkah D: Pratinjau data setelah penerapan One-Hot Encoding pada fitur-fitur nominal non-bertingkat.



Sebelum (Teks)

	pass_status	count
0	Pass	77389
1	Fail	22611

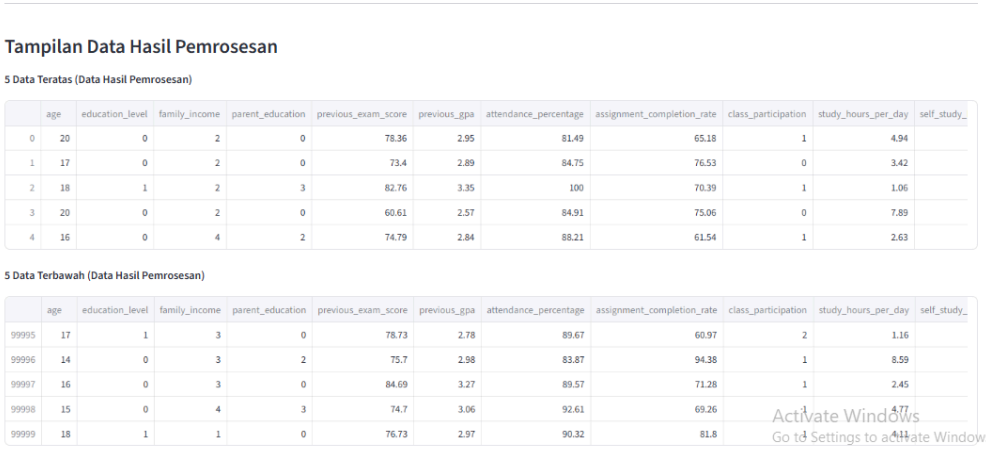
Sesudah (Angka)

	pass_status	count
0	1	77389
1	0	22611

Activate Windows
Go to Settings to activate Windows.

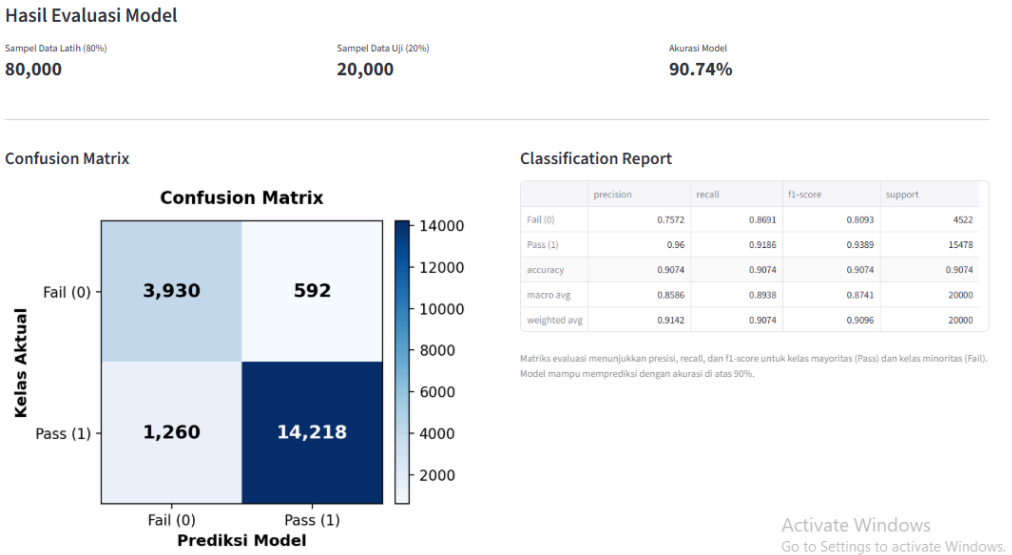
Gambar 4.5 Tangkapan layar Langkah E: Hasil Label Encoding pada variabel target pass_status (Pass menjadi 1 dan Fail menjadi 0).

‘



Gambar 4.6 Tangkapan layar Langkah F & G: Tampilan 5 data teratas dan 5 data terbawah dari dataset setelah seluruh tahapan pemrosesan data selesai dilakukan.

4.3 Hasil Klasifikasi



Berdasarkan hasil pengujian pada 20.000 sampel data uji (20% dari total dataset), model Gaussian Naïve Bayes menunjukkan performa klasifikasi yang sangat baik secara keseluruhan dengan capaian akurasi sebesar **90,74%**. Hasil ini mengindikasikan bahwa sebagian besar prediksi status kelulusan peserta didik berhasil ditebak dengan benar oleh model berdasarkan fitur-fitur independen yang digunakan.

Rincian evaluasi kinerja model berdasarkan matrik evaluasi per kelas dapat dijelaskan sebagai berikut:

- **Kelas Mayoritas (Pass):** Dari total 15.478 sampel aktual berstatus *Pass*, model berhasil memprediksi dengan presisi sebesar **0,96 (96%)**, *recall* sebesar **0,9186 (91,86%)**, serta F1-score sebesar **0,9389 (93,89%)**. Hal ini menunjukkan bahwa model sangat andal dalam mengenali peserta didik yang lulus.

- **Kelas Minoritas (Fail):** Pada kelas minoritas yang terdiri dari 4.522 sampel aktual berstatus *Fail*, model memperoleh presisi sebesar **0,7572 (75,72%)**, *recall* sebesar **0,8691 (86,91%)**, serta F1-score sebesar **0,8093 (80,93%)**. Meskipun terdapat sedikit penurunan presisi akibat ketidakseimbangan kelas target (*class imbalance*), nilai *recall* yang cukup tinggi menunjukkan sensitivitas model yang baik dalam menjaring siswa berisiko tidak lulus.
- **Analisis Confusion Matrix:** Berdasarkan matriks konfusi, model berhasil memprediksi **3.930 True Negatives (TN)** dan **14.218 True Positives (TP)**. Adapun eror prediksi terdiri dari **592 False Positives (FP)** di mana siswa gagal diprediksi lulus, serta **1.260 False Negatives (FN)** di mana siswa lulus diprediksi gagal.

4.4 Pembahasan

4.4.1 Evaluasi Performa Model

Menurut saya, model Gaussian Naïve Bayes ini sudah cukup baik untuk memprediksi kelulusan siswa. Akurasinya 90,74% pada 20.000 data uji. Angka ini perlu dibandingkan dengan baseline: kalau semua siswa ditebak lulus, akurasinya sudah 77,39% karena itulah proporsi kelas Pass. Jadi model benar-benar menambah kemampuan prediksi sekitar 13 poin persentase, bukan sekadar mengikuti proporsi data. Ukuran yang lebih adil untuk kedua kelas adalah macro F1-score sebesar 0,8741. Nilainya lebih rendah dari akurasi karena performa kelas Fail (F1 0,8093) tidak sebaik kelas Pass (F1 0,9389).

4.4.2 Pengaruh Ketidakseimbangan Kelas

Kelas Pass (77,39%) jauh lebih banyak daripada Fail (22,61%), sehingga prior probability condong ke kelas Pass. Namun, kesalahan terbanyak model bukan siswa Fail yang lolos sebagai Pass (592 kasus), melainkan siswa Pass yang salah ditandai Fail (1.260 kasus). Artinya, pengaruh prior tampaknya tertutup oleh faktor lain, yaitu asumsi independensi fitur yang dibahas pada 4.4.3. Stratified split sudah menjaga proporsi kelas di data latih dan data uji, tetapi tidak menghilangkan ketidakseimbangannya.

4.4.3 Asumsi Naïve Bayes

Gaussian Naïve Bayes mengasumsikan setiap fitur saling bebas jika kelasnya diketahui, dan fitur numeriknya berdistribusi normal. Di dataset ini asumsi itu tidak sepenuhnya terpenuhi. Fitur seperti *study_hours_per_day*, *self_study_hours*, dan *practice_tests_completed* kemungkinan berkorelasi, sehingga informasi yang mirip dihitung berulang sebagai bukti terpisah. Akibatnya model cenderung terlalu yakin pada prediksinya, dan ini diduga ikut menurunkan presisi kelas Fail. Selain itu, fitur kategorik yang di-encode (ordinal dan one-hot) tidak berdistribusi normal, padahal Gaussian NB menganggapnya begitu. Meski begitu, akurasi model tetap tinggi, karena yang dibutuhkan untuk klasifikasi hanyalah urutan probabilitas yang benar, bukan nilai probabilitas yang tepat.

4.4.4 Dampak Kesalahan Prediksi

Dari sisi penggunaan, kedua jenis kesalahan berbeda dampaknya. Sebanyak 592 siswa yang sebenarnya tidak lulus tetapi diprediksi lulus adalah kasus yang paling

merugikan, karena siswa berisiko tidak mendapat pendampingan. Sebaliknya, 1.260 siswa lulus yang ditandai berisiko hanya menyebabkan intervensi yang sebenarnya tidak perlu. Jika tujuannya mendeteksi siswa berisiko, recall kelas Fail (86,91%) lebih penting daripada presisinya, dan hasil ini cukup menggembirakan, walaupun masih ada sekitar 13% siswa berisiko yang terlewat.

4.4.5 Keterbatasan dan Saran

Imputasi median dan modus dilakukan pada seluruh data sebelum pembagian data latih/uji, sehingga ada sedikit informasi data uji yang ikut terhitung. Pengaruhnya kemungkinan kecil, tetapi untuk penelitian lebih lanjut, imputasi sebaiknya dihitung dari data latih saja. Model lain yang tidak mengasumsikan independensi fitur, misalnya Logistic Regression atau Random Forest, juga layak dibandingkan.