Tugas Mata Kuliah
Pembelajaran Mesin

KLASIFIKASI KELULUSAN UJIAN SISWA MENGGUNAKAN GAUSSIAN NAÏVE BAYES



Oleh:

Giovanni Khaidzan
10124193

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS KOMPUTER INDONESIA
2026

BAB 1 SUMBER DATA

Data yang digunakan dalam laporan ini diperoleh dari platform Kaggle dengan rincian sebagai berikut:

- **Nama Dataset:** *Student Exam Performance & Success Dataset*
- **Pemilik / Pengunggah:** mobeenfatimah
- **Sumber:** Kaggle
- **Dataset:** https://www.kaggle.com/datasets/mobeenfatimah/student-exam-performance-and-success-dataset
- **Nama File:** *student_exam_performance.csv*
- **Format File:** CSV (Comma-Separated Values)
- **Ukuran Data:** 100.000 baris dan 44 kolom
- **Tanggal Akses:** 11 Oktober 2026

BAB 2 CERITA TENTANG DATA

2.1 Sumber dan Gambaran Umum Dataset

Dataset yang digunakan adalah *The Student Exam Performance & Academic Success Dataset* (https://www.kaggle.com/datasets/mobeenfatimah/student-exam-performance-and-success-dataset). Dataset ini berisi 100.000 catatan siswa dengan 44 fitur dan bersifat semi-sintetis. Data tidak berasal dari survei siswa sungguhan, tetapi dibangkitkan dengan pemodelan non-linear dan kalibrasi standarisasi nilai agar hubungan antarvariabelnya menyerupai kondisi nyata, mulai dari kebiasaan belajar, latar belakang sosial-ekonomi, perilaku belajar, sampai kesejahteraan mental siswa. Dataset ini cocok untuk latihan pemodelan *machine learning*, pembersihan data, dan analisis eksploratif. Setiap baris mewakili satu siswa berusia 14–20 tahun pada jenjang SMA dan perguruan tinggi. Informasinya dapat dikelompokkan menjadi:

- **Latar belakang:** Usia, jenis kelamin, jenjang pendidikan, jenis sekolah, pendapatan keluarga, pendidikan orang tua, wilayah tempat tinggal.
- **Riwayat akademik:** Nilai ujian sebelumnya, IPK sebelumnya, persentase kehadiran, tingkat penyelesaian tugas, partisipasi kelas.
- **Kebiasaan belajar:** Jam belajar, belajar mandiri, les privat, metode belajar, frekuensi revisi, konsistensi, jumlah latihan soal.
- **Gaya hidup dan kesejahteraan:** Jam tidur, kualitas tidur, waktu layar, aktivitas fisik, tingkat stres, motivasi.
- **Akses dan kondisi ujian:** Akses internet, ketersediaan perangkat, penggunaan aplikasi belajar, kesulitan ujian, hari persiapan, kecemasan ujian.
- **Hasil ujian:** *exam_score*, *performance_grade*, *pass_status*, *performance_level*.

2.2 Kondisi Awal Data (Hasil Pemeriksaan)

Ringkasan hasil pemeriksaan kondisi awal data disajikan dalam tabel berikut:

Aspek	Hasil
Jumlah baris	100.000
Jumlah kolom	44
Baris duplikat	Tidak ada
Total nilai kosong	52.161 sel, pada 7 kolom

Rincian nilai kosong per kolom dapat dilihat pada tabel berikut:

Kolom	Jumlah	Persentase
attendance_percentage	9.863	9,86%
time_management_score	9.613	9,61%
notes_quality	8.407	8,41%
previous_gpa	7.793	7,79%
sleep_quality	6.994	6,99%
parent_education	6.526	6,53%
device_availability	2.965	2,96%

Persentase nilai kosong di semua kolom masih di bawah 10%, sehingga tidak ada kolom yang perlu dibuang dan penanganannya dilakukan dengan pengisian nilai. Baris tidak dapat dihapus karena 41.940 baris memiliki minimal satu nilai kosong. Selain itu, ada nilai yang menumpuk di batas atas pada *stress_level* dan *exam_anxiety_level*, serta nilai ekstrem pada beberapa kolom jam.

2.3 Distribusi Kelas Target

Distribusi kelas pada setiap variabel target hasil ujian dijelaskan dalam tabel-tabel berikut:

a. Target *pass_status*

Target	Kelas	Jumlah	Persentase
pass_status	Pass	77.389	77,39%
pass_status	Fail	22.611	22,61%

b. Target *performance_level*

Target	Kelas	Jumlah	Persentase
performance_level	Low	45.123	45,12%
performance_level	Medium	41.999	42,00%
performance_level	High	12.878	12,88%

c. Target *performance_grade*

Target	Kelas	Jumlah	Persentase
performance_grade	D	34.886	34,89%
performance_grade	F	22.611	22,61%
performance_grade	C	21.794	21,79%
performance_grade	B	13.190	13,19%
performance_grade	A	7.519	7,52%

BAB 3 FITUR YANG ADA

Dataset ini terdiri dari 44 kolom yang dapat dikelompokkan ke dalam tiga kategori utama: target, fitur predictor, dan kolom yang dibuang. Rincian pembagian kolom beserta alasannya dijelaskan pada sub-bagian berikut.

3.1 Ringkasan Pembagian Kolom

Tabel berikut merangkum pembagian seluruh kolom yang terdapat pada dataset:

Kategori	Jumlah Kolom	Keterangan
Target (y)	1 (dari 4 pilihan)	*pass_status* dipilih sebagai target utama
Fitur Predictor (X)	13	Digunakan sebagai variabel bebas untuk pemodelan
Kolom Dibuang	30	5 leakage/ID (exam_score, performance_grade, performance_level, questions_correct, dan student_id) + 25 tidak relevan

3.2 Target (y)

Kolom target utama yang dipilih dalam pemodelan ini adalah *pass_status*. Variabel ini merupakan variabel kategorikal biner yang menunjukkan status kelulusan ujian siswa, dengan dua kelas yaitu *Pass* (lulus) dan *Fail* (tidak lulus).

Kolom	Keterangan	Kelas
pass_status	Status kelulusan siswa pada ujian	Pass (77,39%), Fail (22,61%)

Target ini dipilih karena berupa klasifikasi biner sehingga hasil prediksi mudah ditafsirkan, dan distribusinya tidak seimbang sehingga relevan untuk dibahas pada tahap pemrosesan data.

3.3 Fitur yang Digunakan (X)

Berikut adalah 13 fitur predictor yang digunakan dalam pemodelan, dikelompokkan berdasarkan kategori, skala ukurnya, serta alasan penggunaannya:

Kelompok	Fitur	Skala ukur	Alasan digunakan
Riwayat akademik	*previous_exam_score*	Interval	Memiliki hubungan terkuat dengan target
	previous_gpa	Interval	Hubungan kuat; terdapat 7,79% nilai kosong
	attendance_percentage	Rasio	Menunjukkan hubungan; terdapat 9,86% nilai kosong
	assignment_completion_rate	Rasio	Menunjukkan hubungan
Kebiasaan belajar	*study_hours_per_day*	Rasio	Hubungan kuat
	self_study_hours	Rasio	Hubungan kuat
	practice_tests_completed	Rasio	Hubungan kuat
	exam_preparation_days	Rasio	Hubungan kuat
Gaya hidup dan kondisi mental	*sleep_hours*	Rasio	Menunjukkan hubungan
	stress_level	Rasio	Menunjukkan hubungan; nilai menumpuk pada angka 10
	exam_anxiety_level	Interval	Hubungan lemah namun masih ada
Kondisi ujian	*exam_difficulty*	Ordinal	Hubungan cukup kuat
Latar belakang	*family_income*	Ordinal	Hubungan lemah namun masih ada

Metode seleksi: Fitur dipilih berdasarkan nilai mutual information terhadap *pass_status* yang dihitung pada data latih. Kolom dengan nilai di bawah ambang sekitar 0,003 dianggap tidak relevan.

3.4 Kolom yang Dibuang

a. Dibuang Karena Kebocoran Data (Data Leakage) atau Hanya Pengenal

Kolom	Alasan
exam_score	*pass_status* ditentukan langsung dari kolom ini (skor ≥ 50 = Pass)
performance_grade	Diturunkan dari *exam_score*; grade F identik dengan kelas Fail
performance_level	Diturunkan dari *exam_score*

Kolom	Alasan
questions_correct	Berkorelasi 0,975 dengan *exam_score*, sehingga hampir sama dengan jawaban
student_id	Hanya pengenal unik dan tidak memiliki makna prediktif

Kolom-kolom di atas baru tersedia setelah ujian berlangsung atau dihitung dari hasil ujian itu sendiri. Jika dipakai sebagai fitur, model hanya "membaca jawaban" sehingga akurasi mendekati 100% namun tidak menggambarkan kemampuan prediksi sebenarnya, dan model tidak dapat dipakai pada siswa baru yang belum ujian. Sebaliknya, fitur yang digunakan seperti *previous_exam_score* merupakan informasi yang sudah tersedia sebelum ujian dan tidak dihitung dari hasil ujian ini.

b. Dibuang Karena Tidak Relevan (25 Kolom)
Kolom berikut memiliki hubungan dengan *pass_status* yang nyaris nol sehingga tidak membantu model membedakan Pass dan Fail. Hal ini sesuai dengan penanganan fitur tidak relevan melalui seleksi fitur.

Kelompok	Kolom
Demografi dan latar belakang	*age, gender, education_level, school_type, parent_education, urban_rural*
Perilaku belajar	*class_participation, study_consistency, study_environment, study_method, revision_frequency, notes_quality, private_tuition, time_management_score*
Gaya hidup	*sleep_quality, daily_screen_time, physical_activity_hours, break_frequency, motivation_level*
Akses dan pembelajaran online	*internet_access, device_availability, educational_app_usage, online_learning_hours, online_course_hours*
Detail ujian	*questions_attempted*

BAB 4 JENIS DATA BERDASARKAN SKALA PENGUKURAN

Skala pengukuran adalah penggolongan data berdasarkan sifat nilainya. Penggolongan ini tidak mengubah nilai data, tetapi menentukan perlakuan yang tepat pada tahap pemrosesan.

4.1 Pengertian Empat Skala Pengukuran

Skala	Penjelasan	Kolom pada dataset
Nominal	Kategori tanpa urutan. Nilainya hanya dapat dibedakan (sama atau berbeda), tidak dapat diurutkan maupun dihitung rata-ratanya	*pass_status*
Ordinal	Kategori berurutan, tetapi jarak antartingkat tidak pasti	*exam_difficulty, family_income*
Interval	Berupa angka dengan jarak yang bermakna, tetapi tidak memiliki nol mutlak (nilai nol tidak berarti "tidak ada")	*previous_exam_score, previous_gpa, stress_level, exam_anxiety_level*
Rasio	Berupa angka dengan jarak bermakna dan memiliki nol mutlak, sehingga perbandingan seperti "dua kali lipat" bermakna	*attendance_percentage, assignment_completion_rate , study_hours_per_day, self_study_hours, practice_tests_completed, exam_preparation_days, sleep_hours*

Tentang nominal pada dataset ini. Pada 13 fitur yang digunakan tidak ada data nominal. Satu-satunya data nominal adalah target *pass_status*, yaitu dua kategori (Pass dan Fail) tanpa urutan yang bermakna. Beberapa kolom nominal lain terdapat dalam dataset (misalnya *gender, school_type, urban_rural*, dan *study_method*), tetapi tidak digunakan karena dibuang pada tahap seleksi fitur. Karena itu, pemisahan kategori menjadi kolom per kategori (one-hot encoding) tidak diperlukan pada tugas ini.

4.2 Skala pengukuran setiap kolom

Peran	Kolom	Skala	Alasan
Fitur	*previous_exam_score*	Interval	Skor 30-100, jarak bermakna, tanpa nol mutlak
Fitur	*previous_gpa*	Interval	Skor 1,0-4,0, tanpa nol mutlak
Fitur	*attendance_percentage*	Rasio	0% berarti tidak pernah hadir
Fitur	*assignment_completion_rate*	Rasio	0% berarti tidak ada tugas yang diselesaikan
Fitur	*study_hours_per_day*	Rasio	Satuan jam dengan nol mutlak
Fitur	*self_study_hours*	Rasio	Satuan jam dengan nol mutlak
Fitur	*practice_tests_completed*	Rasio	Hasil cacah (0-20), nol berarti tidak ada
Fitur	*exam_preparation_days*	Rasio	Hasil cacah hari, nol berarti tidak ada
Fitur	*sleep_hours*	Rasio	Satuan jam dengan nol mutlak
Fitur	*stress_level*	Interval	Skor tingkat (5-10) tanpa nol mutlak

Peran	Kolom	Skala	Alasan
Fitur	*exam_anxiety_level*	Interval	Skor tingkat (1-10) tanpa nol mutlak
Fitur	*exam_difficulty*	Ordinal	Easy < Medium < Hard, jarak antartingkat tidak pasti
Fitur	*family_income*	Ordinal	Low < Lower-Middle < Middle < Upper-Middle < High, jarak antartingkat tidak pasti
Target	*pass_status*	Nominal	Dua kategori (Pass dan Fail) tanpa urutan

4.3 Contoh nilai sebelum dan sesudah pemrosesan (satu siswa)

Contoh diambil dari satu siswa dengan data lengkap. Baris yang memiliki nilai kosong sudah dihapus pada tahap pembersihan data.

Kolom	Skala	Perlakuan	Sebelum	Sesudah
previous_exam_score	Interval	Tidak diubah	76,61	76,61
previous_gpa	Interval	Tidak diubah	3,03	3,03
attendance_percentage	Rasio	Tidak diubah	89,84	89,84
assignment_completion_rate	Rasio	Tidak diubah	68,99	68,99
study_hours_per_day	Rasio	Tidak diubah	2,81	2,81
self_study_hours	Rasio	Tidak diubah	2,25	2,25
practice_tests_completed	Rasio	Tidak diubah	2	2
exam_preparation_days	Rasio	Tidak diubah	12	12
sleep_hours	Rasio	Tidak diubah	6,95	6,95
stress_level	Interval	Tidak diubah	10	10
exam_anxiety_level	Interval	Tidak diubah	10,0	10,0
exam_difficulty	Ordinal	Ordinal encoding	Easy	1
family_income	Ordinal	Ordinal encoding	High	5
pass_status (target)	Nominal	Tidak diubah	Pass	Pass

Pemetaan ordinal encoding: exam_difficulty: Easy = 1, Medium = 2, Hard = 3. family_income: Low = 1, Lower-Middle = 2, Middle = 3, Upper-Middle = 4, High = 5.

4.4 Penjelasan perlakuan per skala

- **Nominal (pass_status):** berupa label kelas yang diprediksi sehingga tetap berbentuk kategori dan tidak diubah.
- **Ordinal (exam_difficulty, family_income):** berupa teks berurutan. Model hanya dapat menghitung angka, sehingga teks diubah menjadi angka yang mempertahankan urutan. Angka tersebut hanya menyatakan urutan, bukan jarak yang pasti antartingkat.
- **Interval dan rasio (11 fitur):** sudah berupa angka sehingga dipakai dengan nilai aslinya.

4.5 Rekapitulasi Skala

Jumlah	Kolom
Nominal: 1	*pass_status*
Ordinal: 2	*exam_difficulty, family_income*
Interval: 4	*previous_exam_score, previous_gpa, stress_level, exam_anxiety_level*
Rasio: 7	*attendance_percentage, assignment_completion_rate, study_hours_per_day, self_study_hours, practice_tests_completed, exam_preparation_days, sleep_hours*
Total: 14	(13 fitur + 1 target)

4.6 Catatan

previous_exam_score, stress_level, dan exam_anxiety_level dapat diperdebatkan. Ketiganya berupa skor atau tingkat tanpa nol mutlak sehingga dikelompokkan sebagai interval. Pada stress_level dan exam_anxiety_level, secara ketat skala penilaian diri dapat dianggap ordinal, namun karena sudah berupa angka dan jarak antarnilai diasumsikan sama, keduanya diperlakukan sebagai interval dan tidak memerlukan encoding.

BAB 5 PEMROSESAN DATA YANG DIBUTUHKAN DAN ALASANNYA

Pemrosesan dilakukan berurutan: pengecekan duplikat dan inkonsistensi, pembagian data, penanganan nilai kosong, outlier, transformasi kategorikal, normalisasi/standarisasi, seleksi fitur, data tidak seimbang, lalu alasan khusus Gaussian Naïve Bayes. Prinsipnya adalah anti-leakage: data dibagi lebih dulu, semua batas dan aturan dihitung dari data latih saja, dan oversampling hanya pada data latih. Pemilihan 13 kolom dari 44 kolom secara teknis dilakukan paling awal, dan dijelaskan pada 5.7. Setiap sub-bab memakai pola masalah → tindakan → alasan.

5.1 Pengecekan duplikat dan inkonsistensi (versi disederhanakan)

Uraian

- **Masalah**Baris ganda membuat satu siswa terhitung dua kali dan bisa tersebar ke data latih dan uji. Inkonsistensi data (kategori yang ditulis berbeda, penanda kosong berupa teks, tipe data keliru, nilai di luar rentang yang masuk akal) dapat merusak perhitungan statistik
- **Tindakan**Dicek: jumlah baris duplikat, kategori kolom exam_difficulty, family_income, dan pass_status terhadap daftar kategori yang valid, rentang nilai tiap kolom numerik, serta tipe data tiap kolom
- **Hasil**Duplikat 0. Kategori tak dikenal tidak ada. Nilai di luar rentang yang logis tidak ada (persentase 0-100, jam 0-24, IPK 0-4, skala stres dan kecemasan 1-10). Tipe data: 8 kolom float64, 3 kolom int64, 3 kolom teks

(kategorikal). Seluruh kolom numerik terbaca sebagai angka, sehingga tidak ada penanda kosong berupa teks seperti “N/A”

- **Alasan**Pengecekan dilakukan sebelum pembagian data agar baris identik tidak terpisah ke dua sisi (catatan slide 15). Kategori dicek sebelum encoding agar nilai tak dikenal tidak diam-diam menjadi NaN. Karena hasilnya bersih, tidak ada perbaikan yang diperlukan

5.2 Pembagian data (80:20, stratified)

Uraian

- **Masalah**Batas IQR dan oversampling mempelajari sesuatu dari data. Jika data uji ikut terlihat, skor uji menjadi terlalu optimis. Kelas juga tidak seimbang (77:23), sehingga pembagian acak biasa bisa menghasilkan proporsi berbeda di latih dan uji
- **Tindakan**80% latih, 20% uji, stratify=pass_status, random_state=42, dilakukan sebelum penanganan nilai kosong, outlier, dan oversampling
- **Hasil**Latih 80.000 (Pass 61.911 = 77,39%; Fail 18.089 = 22,61%). Uji 20.000 (Pass 15.478 = 77,39%; Fail 4.522 = 22,61%)
- **Alasan**Dengan split lebih dulu, semua statistik hanya berasal dari data latih sehingga data uji benar-benar “belum pernah dilihat” (catatan slide 13-15). Stratified menjaga proporsi kelas. Pembagian tipe 1 (latih:uji, slide 22) dipilih karena Gaussian NB hampir tanpa hiperparameter yang perlu disetel, sehingga data validasi tidak diperlukan

5.3 Penanganan nilai kosong

Uraian

- **Masalah:** Dua dari 13 fitur punya nilai kosong: previous_gpa (latih 6.197, uji 1.596) dan attendance_percentage (latih 7.896, uji 1.967). GaussianNB tidak menerima NaN
- **Tindakan:** Baris yang memiliki nilai kosong dibuang (dropna) pada data latih dan uji secara terpisah; indeks asli tidak di-reset
- **Hasil:** Latih 80.000 → 66.520 (dibuang 13.480 = 16,85%). Uji 20.000 → 16.605 (dibuang 3.395 = 16,98%). Sesudah dibuang, latih Pass 51.456 (77,35%) / Fail 15.064 (22,65%); uji Pass 12.816 (77,18%) / Fail 3.789 (22,82%)
- **Alasan:** Slide 13 membolehkan membuang baris jika tidak membuat data bias. Proporsinya (±17%) memang bukan “sangat kecil”, tetapi data tersisa masih puluhan ribu baris dan proporsi kelas hampir tidak berubah (Fail latih 22,61% → 22,65%). Imputasi satu nilai (median/rata-rata) mengecilkan varians, padahal Gaussian NB hanya memakai rata-rata dan varians per fitur per kelas. Pembuangan baris tidak mempelajari statistik apa pun, sehingga aman juga diterapkan pada data uji.
- **Contoh hitungan:**
    - Persen dibuang = (n_awal − n_akhir) / n_awal × 100 = (80.000 − 66.520) / 80.000 × 100 = 13.480 / 80.000 = 16,85%.
    - Baris yang kosong di kedua kolom (rumus gabungan $|A \cup B| = |A| + |B| - |A \cap B|$): $13.480 = 6.197 + 7.896 - |A \cap B|$, sehingga $|A \cap B| = 14.093 - 13.480 = 613$ baris.

    - Mengapa imputasi dihindari: mengganti proporsi p nilai dengan satu nilai tengah membuat varians menjadi sekitar (1 − p) × varians asli. Untuk previous_gpa (p = 7,79%) varians tinggal ±92,2% dan simpangan baku turun ±4,0%. Untuk attendance_percentage (p = 9,86%) varians tinggal ±90,1% dan simpangan baku turun ±5,1%.
- **Keterbatasan:** Model tidak dapat dipakai untuk siswa yang IPK atau kehadirannya kosong, dan evaluasi hanya pada siswa dengan data lengkap.

5.4 Penanganan outlier

Apa itu outlier. Outlier adalah nilai yang jauh berbeda dari kebanyakan data lain. Contohnya siswa yang belajar 12 jam sehari, padahal kebanyakan siswa belajar 2-4 jam. Nilai seperti ini bisa menggeser rata-rata dan varians, dua hal yang dipakai langsung oleh Gaussian Naïve Bayes. Metode IQR. Data diurutkan dari kecil ke besar, lalu dibagi menjadi empat bagian sama banyak:

- Q1 (kuartil 1): nilai pada urutan 25%, artinya seperempat data berada di bawahnya.
- Q3 (kuartil 3): nilai pada urutan 75%, artinya seperempat data berada di atasnya.
- IQR = Q3 − Q1: lebar rentang yang memuat separuh data bagian tengah.

Nilai dianggap outlier jika berada di luar batas berikut: BB = Q1 − 1,5 × IQR | BA = Q3 + 1,5 × IQR Faktor 1,5 adalah ketentuan baku (aturan Tukey). Pada data berdistribusi normal, batas ini hanya menandai sekitar 0,7% data. Seluruh perhitungan memakai data latih (66.520 baris). Contoh hitungan: study_hours_per_day. Data latih diurutkan. Urutan 25% berada di sekitar siswa ke-16.630 (25% × 66.520), dan nilainya 1,72 jam, jadi Q1 = 1,72 (25% siswa belajar ≤ 1,72 jam). Urutan 75% bernilai 3,91 jam, jadi Q3 = 3,91 (75% siswa belajar ≤ 3,91 jam).

- IQR = 3,91 − 1,72 = 2,19
- BB = 1,72 − 1,5 × 2,19 = 1,72 − 3,285 = −1,565
- BA = 3,91 + 1,5 × 2,19 = 3,91 + 3,285 = 7,195

Siswa yang belajar lebih dari 7,195 jam dianggap outlier atas (ada 1.719 siswa). Batas bawah negatif sehingga tidak ada outlier bawah, karena jam belajar tidak mungkin negatif. Hasil untuk seluruh kolom numerik:

Kolom	**BB**	**BA**	**Di bawah BB**	**Di atas BA**	**Outlier**	**Skewness**	**Keputusan**
previous_exam_score	38,67	100,39	214	0	0,32%	−0,01	Dibiarkan
previous_gpa	1,49	4,08	214	0	0,32%	−0,02	Dibiarkan
attendance_percentage	62,80	106,64	247	0	0,37%	−0,17	Dibiarkan
assignment_completion_rate	37,02	102,43	219	0	0,33%	0,01	Dibiarkan
study_hours_per_day	−1,57	7,20	0	1.719	2,58%	1,13	Winsorizing

Kolom	BB	BA	Di bawah BB	Di atas BA	Outlier	Skewness	Keputusan
self_study_hours	−1,19	5,10	0	1.936	2,91%	1,29	Winsorizing
practice_tests_completed	−0,50	11,50	0	1.142	1,72%	0,54	Winsorizing
exam_preparation_days	−14,50	45,50	0	0	0,00%	0,00	Dibiarkan
sleep_hours	3,73	10,25	214	211	0,64%	0,00	Dibiarkan
stress_level	7,50	11,50	6.652	0	10,00%	−1,58	Dibiarkan
exam_anxiety_level	5,55	12,67	1.901	0	2,86%	−1,42	Dibiarkan

Skewness mengukur kemiringan sebaran: mendekati 0 berarti simetris, positif berarti ekor kanan panjang (ada nilai besar yang jarang), negatif berarti ekor kiri panjang. Tindakan. Winsorizing dilakukan pada tiga kolom dengan ekor kanan panjang: nilai di atas BA diganti dengan BA, nilai di bawah BB diganti dengan BB, dan nilai di dalam batas tidak berubah. Batas dari data latih diterapkan ke data latih dan uji. $x' = \min(\max(x, BB), BA)$ Pada contoh di atas, siswa yang belajar 12,0 jam menjadi $x' = \min(\max(12{,}0; -1{,}565); 7{,}195) = 7{,}195$, sedangkan siswa yang belajar 3,26 jam tidak berubah.

Keterangan	*study_hours_per_day*	*self_study_hours*	*practice_tests_completed*
Nilai berubah, latih	1.719	1.936	1.142
Nilai berubah, uji	429 (2,58%)	486 (2,93%)	309 (1,86%)
Skewness latih, sebelum → sesudah	1,13 → 0,76	1,29 → 0,81	0,54 → 0,31

Kolom hasil cacah (practice_tests_completed). Q1 = 4, Q3 = 7, IQR = 3, sehingga BA = 7 + 1,5 × 3 = 11,5 dan BB = 4 − 4,5 = −0,5. Karena berupa bilangan bulat, BA dibulatkan ke bawah menjadi 11 dan BB ke atas menjadi 0, agar tipe data tetap integer. Siswa dengan 20 tes latihan menjadi 11. Mengapa stress_level dan exam_anxiety_level tidak dipotong. Sebanyak 69,84% siswa bernilai 10, sehingga Q1 = 9, Q3 = 10, IQR = 1, BB = 7,5, dan BA = 11,5. Yang ditandai outlier justru nilai rendah (5, 6, 7), sebanyak 10,00% (6.652 siswa), padahal itu rating yang sah. Yang tidak biasa adalah penumpukan di nilai 10 (efek batas atas skala), dan itu tidak bisa diperbaiki dengan clipping. Alasan. Gaussian NB hanya mengestimasi rata-rata dan varians, dan keduanya sangat peka terhadap nilai ekstrem. Nilai ekstrem pada tiga kolom itu masih mungkin terjadi (mis. belajar 12 jam), jadi baris tidak dibuang agar data tidak berkurang; nilainya cukup dibatasi (slide 14: winsorizing untuk outlier valid tetapi ekstrem). Batas dari data latih mencegah kebocoran dari data uji. Kolom lain punya outlier kurang dari ±0,7% dengan sebaran simetris, sehingga tidak ditangani.

5.5 Transformasi kategorikal ke numerik (ordinal dan nominal)
Uraian

- **Masalah**Dua fitur berbentuk teks berurutan: exam_difficulty (Easy, Medium, Hard) dan family_income (Low, Lower-Middle, Middle, Upper-Middle, High). Gaussian NB hanya dapat menghitung perkalian probabilitas dari angka, sehingga teks harus diubah menjadi angka
- **Tindakan**Ordinal encoding dengan peta yang ditentukan secara manual, bukan acak:
    - *exam_difficulty*: {'Easy': 1, 'Medium': 2, 'Hard': 3}
    - *family_income*: {'Low': 1, 'Lower-Middle': 2, 'Middle': 3, 'Upper-Middle': 4, 'High': 5}
- **Hasil**Seluruh teks di kedua kolom menjadi angka 1-3 dan 1-5 tanpa ada nilai yang terlewat (NaN baru 0)
- **Alasan**Kedua kolom memang punya urutan yang jelas (Easy < Medium < Hard). Ordinal encoding menjaga informasi tingkatan tersebut dalam satu kolom angka (slide 16), berbeda dari one-hot encoding yang akan memecah menjadi 3 dan 5 kolom terpisah dan menambah dimensi. Peta manual menjamin nilai 1 selalu berarti yang paling rendah. Pemetaan ini murni aturan kamus tanpa menghitung statistik apa pun, sehingga tidak ada risiko kebocoran data jika diterapkan langsung ke latih dan uji

Bagaimana dengan data nominal. Pada 13 fitur predictor yang dipakai, tidak ada satu pun yang berskala nominal (mis. gender dan urban_rural sudah dibuang di awal). Satu-satunya kolom nominal adalah target pass_status ('Pass' / 'Fail'), yang tidak perlu di-encode karena Scikit-Learn otomatis mengenali label string pada variabel y.

5.6 Normalisasi / standarisasi
Uraian

- **Masalah**Skala antarfitur sangat berbeda: skor ujian 30-100, IPK 1-4, kehadiran 46,34-100, jam tidur 3-11, hari persiapan 1-30, jumlah tes latihan 0-20, stres 5-10
- **Tindakan**Tidak dilakukan
- **Alasan**Gaussian NB menghitung rata-rata dan varians tiap fitur secara terpisah untuk tiap kelas, sehingga perubahan skala linear tidak mengubah keputusan akhir (dibuktikan di bawah). Nilai asli juga tetap mudah ditafsirkan

5.7 Seleksi fitur
Uraian

- **Masalah**Dataset memiliki 44 kolom, dan tidak semuanya layak dipakai sebagai fitur
- **Tindakan**Dipertahankan 13 fitur (daftar pada Bab 3). Dibuang 30 kolom: 5 karena kebocoran data atau pengenal, 25 karena hubungannya sangat lemah dengan target

AlasanLihat uraian di bawah

a. Kebocoran data dan pengenal (5 kolom)

Kriterianya: apakah informasi sudah ada sebelum ujian, dan apakah dihitung dari hasil ujian itu sendiri.

- ***exam_score***: pass_status ditentukan langsung darinya (skor terendah kelas Pass = 50,0; skor tertinggi kelas Fail = 49,99).
- ***performance_grade***: Fail identik dengan grade F (diverifikasi di kode: True).
- ***performance_level***: diturunkan dari exam_score.
- ***questions_correct***: berkorelasi 0,975 dengan exam_score.
- ***student_id***: hanya pengenal, tanpa makna prediktif.

b. 25 kolom tidak dipilih

Kekuatan hubungan tiap fitur dengan pass_status diukur dengan mutual information:

$$I(X;\ Y) = \Sigma_x \Sigma_y\, p(x, y) \cdot \log\, [\ p(x, y) / (p(x) \cdot p(y))\ ]$$

Nilai 0 berarti X dan Y saling bebas; makin besar berarti makin informatif.

Fitur terpilih	**MI**	**Fitur terpilih**	**MI**
previous_exam_score	0,0703	*assignment_completion_rate*	0,0093
previous_gpa	0,0576	*sleep_hours*	0,0077
exam_difficulty	0,0300	*stress_level*	0,0065
study_hours_per_day	0,0274	*attendance_percentage*	0,0055
self_study_hours	0,0263	*family_income*	0,0038
practice_tests_completed	0,0236	*exam_anxiety_level*	0,0038
exam_preparation_days	0,0232		

Seluruh 13 fitur bernilai ≥ 0,0038, sedangkan 25 kolom lain bernilai ≤ 0,0025 (tertinggi questions_attempted 0,0025, lalu physical_activity_hours 0,0010, time_management_score 0,0004, dan sisanya ≈ 0). Ambang yang dipakai adalah ±0,003, yang berada di antara kedua kelompok.

Hasil perbandingan. [Isi dari Bagian B: akurasi dan F1 kelas Fail dengan semua fitur vs 13 fitur.]

Keterbatasan. Perhitungan MI dilakukan pada keseluruhan data sebagai analisis awal (bukan hanya data latih), sehingga secara ketat bukan murni bebas kebocoran. Kolom yang dibuang bernilai mendekati nol, sehingga dampaknya diperkirakan kecil. Lima kolom tidak dipilih yang memiliki nilai kosong (parent_education, notes_quality, sleep_quality, device_availability, time_management_score) kebetulan juga tidak informatif, sehingga pembuangan baris di 5.3 tidak membesar.

5.8 Penanganan data tidak seimbang (oversampling)

Uraian

- **Masalah**Data latih: Pass 51.456 (77,35%) dan Fail 15.064 (22,65%). Model condong ke kelas mayoritas, padahal Fail justru kelas yang penting dikenali
- **Tindakan**Random oversampling: baris Fail diambil ulang acak dengan pengembalian sampai jumlahnya sama dengan Pass. Hanya pada data latih, setelah split. Urutan baris diacak, indeks asli tidak di-reset
- **Hasil**Data latih menjadi 102.912 baris (Pass 51.456 = 50,0%; Fail 51.456 = 50,0%). Data uji tidak diubah: 16.605 baris (Pass 12.816; Fail 3.789)

AlasanResampling adalah salah satu penanganan di slide 17. Oversampling dipilih agar tidak ada data yang dibuang. Jika dilakukan sebelum split, salinan baris yang sama bisa masuk ke data uji sehingga skor menjadi palsu. Data uji dibiarkan asli supaya metrik mencerminkan kondisi sebenarnya

5.9 Alasan khusus untuk Gaussian Naïve Bayes

5.9 Alasan Pemilihan Gaussian Naïve BayesGaussian Naïve Bayes dipilih tidak hanya berdasarkan ketentuan NIM ganjil, tetapi juga karena sesuai untuk permasalahan klasifikasi status kelulusan siswa (Pass dan Fail). Algoritma ini mampu mengolah fitur numerik, seperti nilai ujian sebelumnya, IPK, persentase kehadiran, dan jam belajar, menggunakan distribusi Gaussian.Selain itu, Gaussian Naïve Bayes memiliki proses perhitungan yang relatif sederhana dan efisien, sehingga sesuai untuk dataset berukuran besar. Algoritma ini juga memungkinkan prediksi berdasarkan probabilitas setiap kelas. Namun, terdapat keterbatasan berupa asumsi distribusi Gaussian dan independensi bersyarat antarfitur. Oleh karena itu, kinerja model perlu dibuktikan melalui evaluasi menggunakan precision, recall, dan F1-score, terutama pada kelas Fail yang jumlahnya lebih sedikit.

BAB 6 HASIL PEMROSESAN

6.1 Lima baris teratas dan terbawah data latih

Tabel berikut menampilkan data latih setelah seluruh pemrosesan (pembuangan nilai kosong, winsorizing, ordinal encoding, dan oversampling). Kolom index_asli adalah nomor baris pada dataset asli.

5 baris teratas5 baris terbawahCatatan pembacaan:

index_asli	previous_exam_score	previous_gpa	attendance_percentage	assignment_completion_rate	study_hours_per_day	self_study_hours	practice_tests_completed	exam_preparation_days	sleep_hours	stress_level	exam_anxiety_level	exam_difficulty	family_income	pass_status
33919	59,68	2,34	85,61	76,83	3,76	2,41	6	26	6,54	7	7,17	1	4	Pass
44758	89,69	3,96	70,09	40,40	3,06	2,05	5	30	5,19	8	9,38	3	4	Pass
77911	55,98	2,16	75,46	76,48	1,86	1,565	1	18,93	10	8,82	3	2	Fail	
78174	74,53	3,03	100,00	80,71	3,78	2,09	5	16	8,76	6	9,13	1	4	Pass
72558	56,88	2,29	69,01	76,03	4,36	3,55	5	5	5,39	10	9,46	3	4	Fail

index_asli	previous_exam_score	previous_gpa	attendance_percentage	assignment_completion_rate	study_hours_per_day	self_study_hours	practice_tests_completed	exam_preparation_days	sleep_hours	stress_level	exam_anxiety_level	exam_difficulty	family_income	pass_status
63931	83,60	3,18	81,91	53,39	1,95	1,37	8	23	7,91	10	9,66	3	4	Pass
80612	55,11	2,19	87,52	70,17	2,50	1,74	5	10	7,78	10	7,16	2	2	Fail
21208	78,80	3,16	69,24	86,02	4,91	2,54	7	18	6,67	10	8,03	1	1	Fail
89538	54,07	1,88	91,37	68,15	4,01	2,37	8	24	4,95	10	10,00	2	2	Pass
10740	71,59	3,00	89,62	65,39	4,26	3,41	5	10	7,13	10	8,82	1	3	Pass

- Semua kolom sudah berupa angka, tanpa nilai kosong. exam_difficulty (1-3) dan family_income (1-5) adalah hasil ordinal encoding.
- Urutan baris telah diacak setelah oversampling, sehingga baris “teratas” dan “terbawah” bukan urutan asli. Indeks asli yang sama dapat muncul lebih dari sekali karena baris kelas Fail digandakan.
- Nilai tidak distandarisasi, sehingga tetap dalam satuan aslinya.

6.2 Ringkasan sebelum dan sesudah pemrosesan

Tahap	Baris	Kolom	Nilai kosong	Pass (%)	Fail (%)
Sebelum: data mentah	100.000	44	52.161	77,39	22,61
Sebelum: 13 fitur + target	100.000	14	17.656	77,39	22,61
Sesudah: data latih	102.912	14	0	50,00	50,00
Sesudah: data uji	16.605	14	0	77,18	22,82

Cara perhitungan

- **a. Jumlah nilai kosong.** Nilai kosong data mentah = jumlah nilai kosong seluruh kolom: 9.863 + 9.613 + 8.407 + 7.793 + 6.994 + 6.526 + 2.965 = 52.161. Pada 13 fitur + target hanya dua kolom yang memiliki nilai kosong: 7.793 (previous_gpa) + 9.863 (attendance_percentage) = 17.656. Setelah pemrosesan semuanya 0.
- **b. Jumlah kolom.** 44 kolom − 30 kolom dibuang (5 kebocoran/ID + 25 tidak relevan) = 14 kolom (13 fitur + 1 target).
- **c. Perubahan jumlah baris tiap tahap:**

Tahap	Data latih	Data uji
Data mentah	100.000	
Setelah split 80:20	80.000	20.000
Setelah buang baris kosong	66.520	16.605
Setelah oversampling	102.912	16.605

  - Persentase baris dibuang, data latih = (80.000 − 66.520) / 80.000 × 100 = 13.480 / 80.000 = 16,85%.
  - Data uji = (20.000 − 16.605) / 20.000 × 100 = 3.395 / 20.000 = 16,98%.

    - Total baris dibuang = 13.480 + 3.395 = 16.875 baris = 16,88% dari 100.000.
    - Data latih setelah oversampling = 2 × jumlah kelas mayoritas = 2 × 51.456 = 102.912.
- **d. Distribusi kelas.** Persentase kelas = jumlah kelas / total baris × 100.
    - Data latih sebelum oversampling: Pass 51.456 / 66.520 = 77,35%; Fail 15.064 / 66.520 = 22,65%.
    - Data latih sesudah: Pass = Fail = 51.456 / 102.912 = 50,00%.
    - Data uji tidak diubah: Pass 12.816 / 16.605 = 77,18%; Fail 3.789 / 16.605 = 22,82%.
    -

6.3 Nilai kosong per kolom

Kolom	Sebelum	Sesudah (latih + uji)
previous_gpa	7.793	0
attendance_percentage	9.863	0
Kolom lainnya (12 kolom)	0	0
Total	**17.656**	**0**

6.4 Perubahan tipe data

Kolom	Sebelum	Sesudah
exam_difficulty	teks (Easy/Medium/Hard)	int64 (1-3)
family_income	teks (Low ... High)	int64 (1-5)
pass_status	teks (Pass/Fail)	teks (tidak diubah)
11 kolom numerik lainnya	float64 / int64	tidak berubah

6.5 Perubahan nilai maksimum pada kolom yang di-winsorizing

Kolom	Max sebelum	Max sesudah / Batas atas (BA)
study_hours_per_day	12,0	7,195
self_study_hours	10,0	5,095
practice_tests_completed	20	11

Cara perhitungan. Winsorizing: $x' = \min(\max(x, BB), BA)$. Nilai maksimum sesudah sama dengan BA, misalnya study_hours_per_day: $\min(\max(12{,}0; -1{,}565); 7{,}195) = 7{,}195$.

6.6 Kesimpulan

Pemrosesan menghasilkan data yang siap dipakai Gaussian Naïve Bayes: tidak ada nilai kosong (17.656 → 0), seluruh 13 fitur berupa angka, nilai ekstrem pada tiga kolom telah dibatasi, data latih seimbang (50:50), dan data uji tetap pada distribusi aslinya (±77:23).

BAB 7 HASIL MODEL DAN EVALUASI

7.1 Skema evaluasi

Uraian

- **Model:** Gaussian Naïve Bayes (GaussianNB, parameter bawaan)
- **Data latih:** 102.912 baris (hasil oversampling), hanya dipakai untuk melatih model
- **Data uji:** 16.605 baris (distribusi asli), hanya dipakai untuk evaluasi akhir
- **Kelas positif:** Fail, yaitu kelas minoritas yang penting dikenali. Precision, recall, dan F1 dibaca untuk kelas ini

Pemeriksaan: Tidak ada siswa yang sama di data latih dan data uji (indeks tidak beririsan), sehingga tidak ada kebocoran data

7.2 Cara kerja dan parameter model

Untuk siswa dengan fitur $x = (x_1, ..., x_{13})$, model menghitung skor tiap kelas k (Pass atau Fail): $P(k \mid x) \propto P(k) \times \prod_{\square} N(x_{\square} ; \mu_{\square\square}, \sigma^2_{\square\square})$ dengan kepadatan normal $N(x ; \mu, \sigma^2) = [1 / \sqrt{(2\pi\sigma^2)}] \times \exp(-(x - \mu)^2 / (2\sigma^2))$. Kelas dengan skor terbesar menjadi prediksi.

Parameter hasil pelatihan. Prior kelas Fail = Pass = 0,5000 (karena data latih seimbang). Rata-rata (dan simpangan baku) tiap fitur:

Fitur	Fail	Pass
previous_exam_score	61,851 (10,234)	71,776 (10,728)
previous_gpa	2,474 (0,437)	2,870 (0,453)
attendance_percentage	82,880 (7,965)	85,163 (7,820)
assignment_completion_rate	66,640 (11,624)	70,682 (12,093)
study_hours_per_day	2,284 (1,258)	3,167 (1,658)
self_study_hours	1,604 (0,929)	2,204 (1,199)
practice_tests_completed	4,555 (2,131)	5,742 (2,416)
exam_preparation_days	12,879 (9,063)	16,289 (8,358)
sleep_hours	6,733 (1,183)	7,070 (1,192)
stress_level	9,593 (0,860)	9,312 (1,129)
exam_anxiety_level	9,152 (1,161)	8,867 (1,397)
exam_difficulty	2,321 (0,656)	1,909 (0,692)
family_income	2,504 (1,194)	2,762 (1,229)

Siswa kelas Fail rata-rata memiliki nilai ujian dan IPK sebelumnya lebih rendah, belajar dan berlatih lebih sedikit, waktu persiapan lebih pendek, serta menghadapi ujian yang lebih sulit, sedangkan tingkat stres dan kecemasannya sedikit lebih tinggi.

Rata-rata (*mean*) diperoleh dengan menjumlahkan seluruh nilai pada suatu fitur, kemudian membaginya dengan jumlah data pada kelas yang bersangkutan. Perhitungan dilakukan secara terpisah untuk kelas Fail dan Pass agar diperoleh karakteristik masing-masing kelas.

Simpangan baku (*standard deviation*) digunakan untuk mengukur tingkat penyebaran nilai data terhadap rata-ratanya. Perhitungannya dilakukan dengan mengurangi setiap nilai data dengan rata-rata, menguadratkan hasil selisih tersebut, menjumlahkan seluruh hasil kuadrat, kemudian membaginya dengan jumlah data. Setelah itu, akar kuadrat dari hasil pembagian tersebut dihitung untuk memperoleh simpangan baku. Nilai rata-rata dan simpangan baku yang diperoleh digunakan oleh model Gaussian Naive Bayes untuk menggambarkan distribusi setiap fitur pada kelas Fail dan Pass.

7.3 Hasil pada data uji

Confusion matrix (Fail = kelas positif):

	Prediksi Pass	**Prediksi Fail**	**Jumlah**
Aktual Pass	TN = 9.218	FP = 3.598	12.816
Aktual Fail	FN = 721	TP = 3.068	3.789
Jumlah	9.939	6.666	16.605

TN = Pass terprediksi Pass, FP = Pass salah terprediksi Fail, FN = Fail salah terprediksi Pass, TP = Fail terprediksi Fail.

Cara perhitungan metrik:

Metrik	**Rumus**	**Hitungan**	**Hasil**
Accuracy	(TP + TN) / total	(3.068 + 9.218) / 16.605 = 12.286 / 16.605	0,7399
Precision (Fail)	TP / (TP + FP)	3.068 / (3.068 + 3.598) = 3.068 / 6.666	0,4602
Recall (Fail)	TP / (TP + FN)	3.068 / (3.068 + 721) = 3.068 / 3.789	0,8097
F1 (Fail)	2TP / (2TP + FP + FN)	6.136 / (6.136 + 3.598 + 721) = 6.136 / 10.455	0,5869
Precision (Pass)	TN / (TN + FN)	9.218 / (9.218 + 721) = 9.218 / 9.939	0,9275
Recall (Pass)	TN / (TN + FP)	9.218 / (9.218 + 3.598) = 9.218 / 12.816	0,7193
F1 (Pass)	2TN / (2TN + FN + FP)	18.436 / (18.436 + 721 + 3.598) = 18.436 / 22.755	0,8102
Rata-rata F1 (macro)	(F1 Fail + F1 Pass) / 2	(0,5869 + 0,8102) / 2	0,6985
ROC-AUC	peluang skor Fail siswa Fail > skor Fail siswa Pass (dari sklearn)	-	0,8488

Pembanding. Jika model menebak "Pass" untuk semua siswa, accuracy = 12.816 / 16.605 = 0,7718.

Interpretasi.

- **Recall Fail 80,97%:** dari 3.789 siswa yang benar-benar tidak lulus, model berhasil mengenali 3.068, dan hanya 721 yang lolos terdeteksi.
- **Precision Fail 46,02%:** dari 6.666 siswa yang diprediksi Fail, hanya 3.068 yang benar-benar Fail. Model memprediksi Fail untuk 40,14% siswa (6.666 / 16.605), padahal proporsi Fail sebenarnya 22,82%.
- **Accuracy 73,99%:** lebih rendah daripada menebak Pass untuk semua siswa (77,18%). Ini wajar karena model dilatih agar sensitif terhadap Fail (prior 50:50 dari oversampling), sehingga lebih banyak Pass yang salah dicurigai Fail. Karena data uji tidak seimbang, accuracy saja menyesatkan, sehingga precision, recall, dan F1 per kelas lebih tepat dipakai.
- **ROC-AUC 0,8488:** jika diambil satu siswa Fail dan satu siswa Pass secara acak, model memberi skor Fail lebih tinggi pada siswa Fail dengan peluang 84,88% (nilai 0,5 setara menebak acak, 1,0 sempurna).

7.4 Pemeriksaan overfitting

Metrik	Data latih	Data uji	Selisih
Accuracy	0,7722	0,7399	0,0323
Precision (Fail)	0,7476	0,4602	0,2874
Recall (Fail)	0,8217	0,8097	0,0120
F1 (Fail)	0,7829	0,5869	0,1960
ROC-AUC	0,8543	0,8488	0,0055

Interpretasi. Recall dan ROC-AUC yang tidak bergantung pada proporsi kelas hampir sama pada data latih dan uji (selisih 0,0120 dan 0,0055), sehingga tidak ada tanda overfitting. Selisih besar pada precision dan F1 disebabkan oleh perbedaan proporsi kelas, bukan overfitting. Precision dipengaruhi proporsi Fail pada data. Pada data uji: TPR = recall Fail = 0,8097 dan tingkat alarm palsu FPR = FP / (FP + TN) = 3.598 / 12.816 = 0,2807. Jika data uji berproporsi 50:50 seperti data latih, precision-nya akan menjadi TPR / (TPR + FPR) = 0,8097 / (0,8097 + 0,2807) = 0,7425, hampir sama dengan precision data latih (0,7476). Performa yang sedang pada kedua data menunjukkan keterbatasan model, bukan overfitting (lihat 7.7).

7.5 Contoh prediksi lengkap (1 siswa)

Dua contoh berikut (satu siswa Fail dan satu siswa Pass dari data uji) menunjukkan bagaimana model menggabungkan 13 fitur untuk menghasilkan prediksi.

a. Contoh siswa aktual Fail (indeks asli 77911)

Nilai fitur siswa: previous_exam_score = 55,98 | previous_gpa = 2,16 | attendance_percentage = 75,46 | assignment_completion_rate = 76,48 | study_hours_per_day = 1,86 | self_study_hours = 1,565 (hasil winsorizing dari

1,22) | practice_tests_completed = 1 | exam_preparation_days = 18,93 | sleep_hours = 10,0 | stress_level = 8,82 | exam_anxiety_level = 3,0 | exam_difficulty = 2 (Medium) | family_income = 2 (Lower-Middle). Target asli = Fail. Kepadatan peluang per fitur:

Fitur (x)	f(x | Fail)	f(x | Pass)
previous_exam_score	0,0328	0,0126
previous_gpa	0,7040	0,2573
attendance_percentage	0,0325	0,0237
assignment_completion_rate	0,0246	0,0232
study_hours_per_day	0,3004	0,1768
self_study_hours	0,4288	0,2882
practice_tests_completed	0,0467	0,0244
exam_preparation_days	0,0246	0,0372
sleep_hours	0,0075	0,0165
stress_level	0,3096	0,3206
exam_anxiety_level	0,0000000028	0,0000000411
exam_difficulty	0,5399	0,5722
family_income	0,3053	0,2681

Hasil perkalian seluruh kepadatan peluang:

- Fail: $0{,}5 \times \prod f(x\square \mid \text{Fail}) = 1{,}29 \times 10^{-13}$
- Pass: $0{,}5 \times \prod f(x\square \mid \text{Pass}) = 7{,}65 \times 10^{-16}$

Probabilitas akhir (dinormalisasi):

- $P(\text{Fail} \mid x) = 1{,}29 \times 10^{-13} / (1{,}29 \times 10^{-13} + 7{,}65 \times 10^{-16}) = 0{,}9941$ (99,41%)
- $P(\text{Pass} \mid x) = 7{,}65 \times 10^{-16} / (1{,}29 \times 10^{-13} + 7{,}65 \times 10^{-16}) = 0{,}0059$ (0,59%)

Keputusan model: Fail. Prediksi BENAR (aktual Fail, terprediksi Fail / True Positive).

b. Contoh siswa aktual Pass (indeks asli 33919)

Nilai fitur siswa: previous_exam_score = 59,68 | previous_gpa = 2,34 | attendance_percentage = 85,61 | assignment_completion_rate = 76,83 | study_hours_per_day = 3,76 | self_study_hours = 2,41 | practice_tests_completed = 6 | exam_preparation_days = 26,0 | sleep_hours = 6,54 | stress_level = 7,0 | exam_anxiety_level = 7,17 | exam_difficulty = 1 (Easy) | family_income = 4 (Upper-Middle). Target asli = Pass. Kepadatan peluang per fitur:

Fitur (x)	f(x | Fail)	f(x | Pass)
previous_exam_score	0,0381	0,0198
previous_gpa	0,8703	0,4434
attendance_percentage	0,0472	0,0509

Fitur (x)	f(x | Fail)	f(x | Pass)
assignment_completion_rate	0,0234	0,0290
study_hours_per_day	0,1588	0,2237
self_study_hours	0,2939	0,3289
practice_tests_completed	0,1487	0,1572
exam_preparation_days	0,0155	0,0243
sleep_hours	0,3197	0,3030
stress_level	0,0050	0,0423
exam_anxiety_level	0,0797	0,1355
exam_difficulty	0,0812	0,2418
family_income	0,1515	0,1863

Hasil perkalian seluruh kepadatan peluang:

- Fail: $0,5 \times \prod f(x_i \mid \text{Fail}) = 7,63 \times 10^{-13}$
- Pass: $0,5 \times \prod f(x_i \mid \text{Pass}) = 3,06 \times 10^{-11}$

Probabilitas akhir (dinormalisasi):

- $P(\text{Fail} \mid x) = 7,63 \times 10^{-13} / (7,63 \times 10^{-13} + 3,06 \times 10^{-11}) = 0,0243$ (2,43%)
- $P(\text{Pass} \mid x) = 3,06 \times 10^{-11} / (7,63 \times 10^{-13} + 3,06 \times 10^{-11}) = 0,9757$ (97,57%)

Keputusan model: Pass. Prediksi BENAR (aktual Pass, terprediksi Pass / True Negative).

7.6 Analisis pendukung

a. Pengaruh prior kelas. Oversampling membuat prior model 50:50. Sebagai pembanding, model dilatih ulang dengan prior sesuai distribusi asli (Pass 0,7739; Fail 0,2261):

Model	Accuracy	Precision (Fail)	Recall (Fail)	F1 (Fail)	ROC-AUC	Diprediksi Fail
Prior 50:50 (model utama)	0,7399	0,4602	0,8097	0,5869	0,8488	6.666 (40,14%)
Prior asli (77:23)	0,8100	0,5748	0,6426	0,6069	0,8488	4.236 (25,51%)

Confusion matrix prior asli: TN = 11.015, FP = 1.801, FN = 1.354, TP = 2.435. Cek: precision = 2.435 / (2.435 + 1.801) = 0,5748; recall = 2.435 / (2.435 + 1.354) = 0,6426; F1 = 4.870 / (4.870 + 1.801 + 1.354) = 0,6069.

Prior hanya menggeser ambang keputusan: odds akhir = odds prior × likelihood ratio. Dengan prior asli, odds prior (Fail:Pass) = 0,2261 / 0,7739 = 0,2922, sehingga Fail baru diprediksi jika LR > 1 / 0,2922 ≈ 3,42. Dengan prior 50:50, cukup LR > 1. Karena urutan peluang tidak berubah, ROC-AUC sama (0,8488). Pilihan prior adalah soal tujuan: prior 50:50 cocok jika kegagalan siswa yang

terlewat lebih merugikan (recall tinggi), sedangkan prior asli cocok jika alarm palsu ingin ditekan (precision lebih tinggi). Hasil ini hanya pembanding dan tidak dipakai untuk mengganti model utama.

b. Pengaruh skala. Model dilatih tanpa penskalaan, dengan standarisasi, dan dengan normalisasi (parameter dari data latih):

Skenario	Accuracy	Precision (Fail)	Recall (Fail)	F1 (Fail)	ROC-AUC	Prediksi berbeda
Tanpa penskalaan	0,7399	0,4602	0,8097	0,5869	0,8488	0
Standarisasi (z-score)	0,7399	0,4602	0,8097	0,5869	0,8488	0
Normalisasi (min-max)	0,7399	0,4602	0,8097	0,5869	0,8488	0

Hasil identik dan tidak ada satu pun prediksi yang berubah dari 16.605 siswa uji, sehingga mendukung keputusan tidak melakukan penskalaan (Bab 5.6).

7.7 Keterbatasan dan kesimpulan

Keterbatasan:

- Asumsi independensi tidak terpenuhi: study_hours_per_day–self_study_hours dan previous_exam_score–previous_gpa berkorelasi 0,95, sehingga informasi yang sama terhitung dua kali dan probabilitas keluaran cenderung terlalu ekstrem (mis. P(Fail) = 0,004 atau 0,930).
- stress_level dan exam_anxiety_level tidak berdistribusi normal (menumpuk di nilai 10), tidak sesuai asumsi Gaussian.
- Evaluasi hanya pada siswa dengan data lengkap (16.605 dari 20.000 siswa uji), dan oversampling menduplikasi baris Fail pada data latih.
- Dataset bersifat semi-sintetis, sehingga hasil belum tentu berlaku pada data siswa sungguhan.

Kesimpulan. Gaussian Naïve Bayes dengan 13 fitur mampu mengenali 80,97% siswa yang tidak lulus (recall Fail) dengan ROC-AUC 0,8488, dan tidak overfitting (recall dan AUC latih ≈ uji). Harganya adalah precision Fail yang rendah (46,02%) sehingga accuracy (73,99%) berada di bawah penebak "Pass semua" (77,18%). Karena itu performa model sebaiknya dinilai dari recall, precision, F1, dan AUC kelas Fail, bukan dari accuracy saja.